Adversarial Attacks on MNIST and CIFAR-10

1. Introduction

이미지 분류 모델에 대해 adversarial attack을 구현하고, 공격 방식에 따라 결과가 어떻게 달라지는지 비교했다. 실험은 MNIST와 CIFAR-10 두 데이터셋에서 진행했고, 사용한 공격은 다음 네 가지이다.

- Untargeted FGSM
- Targeted FGSM
- Untargeted PGD
- Targeted PGD

MNIST에서는 직접 CNN을 구현했고, CIFAR-10에서는 ResNet18 구조를 사용했다. 먼저 clean test set에서 기본 정확도를 확인한 뒤, 여러 `eps` 값에 대해 공격 성공률을 비교했다. 마지막으로 adversarial example과 perturbation을 함께 시각화해서, 수치뿐 아니라 실제 이미지 변화도 같이 확인했다.

---

2. Clean Accuracy

공격 실험에 들어가기 전에, 먼저 clean test data에서 모델이 충분한 성능을 내는지 확인했다.

- MNIST Test Accuracy: 98.99%
- CIFAR-10 Test Accuracy: 86.09%

두 데이터셋 모두 기준을 만족했다. 따라서 이후에 관찰한 공격 성공률은 단순히 모델이 덜 학습되어서 생긴 결과라기보다, 실제 adversarial perturbation이 예측에 영향을 준 결과로 해석할 수 있다.

---

3. Attack Success Rate

3.1 MNIST

eps	FGSM-U	FGSM-T	PGD-U	PGD-T
0.05	5.00%	0.00%	5.00%	0.00%
0.10	11.00%	2.00%	15.00%	2.00%
0.20	37.00%	4.00%	54.00%	15.00%
0.30	66.00%	21.00%	89.00%	69.00%

3.2 CIFAR-10

eps	FGSM-U	FGSM-T	PGD-U	PGD-T
0.05	37.00%	1.00%	40.00%	1.00%
0.10	60.00%	3.00%	70.00%	7.00%
0.20	83.00%	15.00%	94.00%	35.00%
0.30	94.00%	33.00%	100.00%	72.00%

```
(advattack) illeam@illeam:/mnt/c/Users/mirac/OneDrive/바탕 화면/ram/2026/신인지/assignment1$ python test.py
Training MNIST model...
MNIST Epoch 1/3, Test Accuracy: 97.99%
MNIST Epoch 2/3, Test Accuracy: 98.53%
MNIST Epoch 3/3, Test Accuracy: 98.99%

=== Attack Success Rates on MNIST ===
eps     FGSM-U  FGSM-T  PGD-U   PGD-T
0.05    4.00%   1.00%   5.00%   1.00%
0.10    11.00%  2.00%   15.00%  2.00%
0.20    56.00%  12.00%  89.00%  40.00%
0.30    91.00%  33.00%  100.00% 97.00%
Saved MNIST visualization images to results/
/home/illeam/anaconda3/envs/advattack/lib/python3.11/site-packages/torchvision/datasets/cifar.py:83: VisibleDeprecationWarning: dtype(): alig
n should be passed as Python or NumPy boolean but got `align=0`. Did you mean to pass a tuple to create a subarray type? (Deprecated NumPy 2.
4)
  entry = pickle.load(f, encoding="latin1")

Training CIFAR-10 model...
CIFAR-10 Epoch 1/10, Test Accuracy: 54.71%
CIFAR-10 Epoch 2/10, Test Accuracy: 64.06%
CIFAR-10 Epoch 3/10, Test Accuracy: 75.08%
CIFAR-10 Epoch 4/10, Test Accuracy: 73.97%
CIFAR-10 Epoch 5/10, Test Accuracy: 80.48%
CIFAR-10 Epoch 6/10, Test Accuracy: 82.46%
CIFAR-10 Epoch 7/10, Test Accuracy: 83.88%
CIFAR-10 Epoch 8/10, Test Accuracy: 80.20%
CIFAR-10 Epoch 9/10, Test Accuracy: 85.52%
CIFAR-10 Epoch 10/10, Test Accuracy: 86.09%

=== Attack Success Rates on CIFAR-10 ===
eps     FGSM-U  FGSM-T  PGD-U   PGD-T
0.05    95.00%  37.00%  100.00% 100.00%
0.10    94.00%  23.00%  100.00% 100.00%
0.20    87.00%  12.00%  100.00% 100.00%
0.30    86.00%  11.00%  100.00% 100.00%
Saved CIFAR-10 visualization images to results/
```

Windows 정품 인증
[설정]으로 이동하여 Windows를 정품 인증합니다.

4. Why Some Attacks Were More Effective Than Others

실험 결과를 보면 전체적으로 PGD가 FGSM보다 더 강한 공격으로 나타났다. 예를 들어 MNIST에서 `eps=0.30`일 때 untargeted FGSM은 66%였지만 untargeted PGD는 89%까지로 올라갔다. CIFAR-10에서도 같은 `eps=0.30`에서 untargeted FGSM은 94%, untargeted PGD는 100%였다. 같은 perturbation budget 안에서도 PGD가 더 효과적으로 decision boundary를 넘겼다고 볼 수 있다.

내가 보기에는 이 차이의 핵심은 gradient를 얼마나 세밀하게 조정하느냐에 있다. FGSM은 gradient sign을 한 번만 사용하기 때문에 계산은 단순하지만, 공격 방향이 다소 거칠다. 반면 PGD는 작은 step으로 여러 번 업데이트하면서 매 단계마다 gradient를 다시 계산한다. 그래서 한 번에 크게 밀기보다, 더 안정적으로 오분류가 일어나는 방향을 찾아간다. 실제로도 작은 `eps`에서는 FGSM과 PGD의 차이가 아주 크지 않았지만, `eps`가 커질수록 PGD의 우세가 훨씬 뚜렷해졌다.

또 하나 분명했던 점은 untargeted attack이 targeted attack보다 훨씬 쉽게 성공한다는

것이다. 예를 들어 MNIST에서 `eps=0.10`일 때 untargeted FGSM은 11%였지만 targeted FGSM은 2%에 그쳤다. CIFAR-10에서도 `eps=0.10`일 때 untargeted PGD는 70%, targeted PGD는 7%였다. 이 결과는 자연스럽다고 생각한다. untargeted attack은 정답만 벗어나면 성공이기 때문에 조건이 비교적 느슨하다. 반면 targeted attack은 모델 출력을 특정한 목표 클래스까지 정확히 밀어 넣어야 하므로 훨씬 더 어렵다.

---

5. Effect of `eps` and the Trade-off Between Success Rate and Visibility

`eps`는 공격 강도를 결정하는 가장 중요한 하이퍼파라미터였다. 내 실험에서는 거의 모든 경우에서 `eps`가 커질수록 공격 성공률이 상승했다. 예를 들어 CIFAR-10 untargeted PGD는 `eps=0.05`에서 40%, `eps=0.10`에서 70%, `eps=0.20`에서 94%, `eps=0.30`에서 100%까지 올라갔다. MNIST untargeted PGD 역시 `5% → 15% → 54% → 89%`로 꾸준히 증가했다. 이 결과만 봐도 `eps`가 커질수록 모델을 흔들 수 있는 범위가 넓어지고, 공격 성공률도 높아진다는 점을 확인할 수 있다.

하지만 `eps`를 키우는 것이 모든 부분에서 좋은 것은 아니었다. `eps`가 커질수록 perturbation도 함께 커지기 때문에, 공격은 강해지지만 이미지의 자연스러움은 줄어든다. 실제 시각화 결과를 보면 작은 `eps`에서는 원본과 adversarial image의 차이가 거의 눈에 띄지 않았지만, `eps=0.30`에서는 perturbation이 훨씬 뚜렷하게 보였다. 결론적으로, 작은 `eps`는 덜 눈에 띄지만 공격력이 약하고, 큰 `eps`는 공격력은 강하지만 더 쉽게 보인다는 trade-off가 분명하게 있었다.

내가 특히 흥미롭게 느낀 점은, 이 trade-off가 데이터셋에 따라 조금 다르게 보였다는 것이다. MNIST는 숫자 모양과 배경이 단순해서 perturbation이 커지면 형태가 흔들리는 것이 비교적 눈에 잘 들어왔다. 반면 CIFAR-10은 색상과 질감이 더 복잡해서 perturbation이 섞여 들어가도 사람이 보기에는 덜 눈에 띄는 경우가 있었다. 그런데도 공격 성공률은 CIFAR-10에서 더 빠르게 올라갔다. 사람 눈에는 큰 변화가 없어 보여도 모델은 훨씬 더 민감하게 반응할 수 있다는 점이 인상적이었다.

---

6. My Interpretation of the Experimental Results

이번 실험에서 가장 인상적이었던 점은 모델 정확도가 높다고 해서 공격에 강한 것은 아니라는 사실이었다. MNIST는 98.99%, CIFAR-10은 86.09%로 clean accuracy는 충분히 높았지만, adversarial perturbation이 들어가자 공격 성공률은 빠르게 올라갔다. 특히 CIFAR-10에서는 clean accuracy가 86% 이상이었는데도 `eps=0.30`에서 untargeted PGD가 100%에 도달했다. 처음에는 CIFAR-10이 더 복잡한 데이터셋이기 때문에 오히려 더 robust할 수도 있겠다고 생각했는데, 실제 결과는 그 반대에 가까웠다. 복잡한 이미지일수록 작은 방향 변화에도 decision boundary 근처에서 더 쉽게 흔들릴 수 있다는 점을 보여주는 결과였다고 생각한다.

또한 예상보다 더 흥미로웠던 부분은 작은 `eps` 구간에서 targeted attack이 거의 작동하지 않았다는 점이다. 예를 들어 MNIST의 targeted FGSM은 `eps=0.05`에서 0%, `eps=0.10`에서도 2%밖에 되지 않았다. CIFAR-10 targeted FGSM도 `1%`, `3%` 수준이었다. 처음에는 targeted attack도 어느 정도는 따라올 거라고 생각했지만, 실제로는 특정 클래스로 정확히 보내는 것이 생각보다 훨씬 어려웠다. 반면 `eps`가 커지면서 targeted PGD는 꽤 빠르게 올라갔다. 예를 들어 CIFAR-10 targeted PGD는 `eps=0.30`에서 72%까지 도달했다. 이 결과를 보면 반복적인 업데이트가 있을 때 targeted attack의 효과가 훨씬 커진다는 점을 알 수 있다.

전체적으로 보면, 공격의 효과는 단순히 "FGSM이냐 PGD냐"만으로 결정되지 않았다. '공격 방식(FGSM vs PGD), 공격 목표(targeted vs untargeted), 그리고 `eps`'의 크기가 함께 작용하면서 결과가 달라졌다. 그래서 이번 실험에서는 어느 한 가지 요인만 보기보다, 조건이 바뀔 때 결과가 어떻게 달라지는지를 같이 보는 것이 더 중요하다고 느꼈다.

---

7. Unexpected or Notable Observations

실험하면서 예상 밖이라고 느낀 부분도 몇 가지 있었다.

첫째, MNIST에서도 `eps=0.30`이 되면 targeted PGD가 69%까지 올라갔다는 점이다. MNIST는 단순한 숫자 이미지라서 targeted attack은 끝까지 잘 안 될 수도 있다고 생각했는데, `eps`가 충분히 커지자 생각보다 강하게 목표 클래스로 밀어 넣을 수 있었다. 단순한 데이터라고 여도 targeted attack에 꽤나 잘 흔들릴 수 있다는 점이 인상적이었다..

둘째, CIFAR-10의 untargeted 공격 성공률이 매우 빠르게 증가했다. 특히 `eps=0.20`에서 untargeted PGD가 94%, `eps=0.30`에서는 100%에 도달했다. CIFAR-10은 clean accuracy 자체는 높았지만, 더 복잡한 모델임에도 불구하고 adversarial perturbation에는 오히려 상당히 취약한 모습이 보였다.

---

8. Visualization

시각화 결과에서도 수치와 비슷한 흐름이 확인되었다. 작은 `eps`에서는 원본 이미지와 adversarial image가 거의 비슷해 보였고, perturbation도 약하게 나타났다. 반면 큰 `eps`에서는 perturbation이 훨씬 뚜렷해졌고, 모델의 예측도 더 자주 바뀌었다.

특히 PGD는 같은 `eps`에서도 FGSM보다 예측을 더 강하게 흔드는 경우가 많았다. 즉, 성공률 표에서 보였던 차이가 실제 adversarial example에서도 어느 정도 그대로 드러났다. 수치와 시각화가 서로 비슷한 방향을 보여준다는 점에서 결과 해석이 더 자연스러웠다.

---

9. Conclusion

이번 실험에서는 MNIST와 CIFAR-10에서 FGSM과 PGD 기반 adversarial attack을 구현하고 비교하였다. 실험 결과를 정리하면 다음과 같다.

- PGD는 FGSM보다 전반적으로 더 강한 공격이었다.
- Untargeted attack은 targeted attack보다 훨씬 쉽게 성공했다.
- `eps`가 커질수록 공격 성공률은 증가했지만 perturbation도 더 눈에 띄었다.
- CIFAR-10은 MNIST보다 perturbation에 더 민감한 경향을 보였다.

이번 과제를 통해 adversarial attack은 단순한 이론적 개념이 아니라, 실제 모델의 예측을 상당히 쉽게 흔들 수 있는 강력한 방법이라는 점을 확인할 수 있었다. 또한 공격 방식, 반복 여부, 그리고 `eps`의 크기가 결과에 큰 영향을 준다는 점도 직접 실험을 통해 확인할 수 있었다.

10. 참조

이번 실험에서는 chatGPT를 참조했다.